

## 2.11 Ликбез по линалу. Многомерные распределения. Регрессия. Катарсис.

### Пререквизиты

Вектор - столбец.  $n$  - количество объектов,  $d$  - количество признаков (размерность пространства)

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix}$$
$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix} = \begin{pmatrix} x_{1,1} & \dots & x_{1,d} \\ \vdots & & \vdots \\ x_{n,1} & \dots & x_{n,d} \end{pmatrix}$$

Матожидание вектора (для матрицы - аналогично):

$$\mathbb{E}\mathbf{x} = \begin{pmatrix} \mathbb{E}x_1 \\ \vdots \\ \mathbb{E}x_n \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_d \end{pmatrix}$$

Ковариация двух векторов:

$$\text{Cov}(\mathbf{x}, \mathbf{y}) = \begin{pmatrix} \text{Cov}(x_1, y_1) & \dots & \text{Cov}(x_1, y_d) \\ \vdots & \dots & \vdots \\ \text{Cov}(x_d, y_1) & \dots & \text{Cov}(x_d, y_d) \end{pmatrix}$$

Дисперсия - ковариация одного и того же вектора

$$\mathbb{V}\mathbf{x} = \begin{pmatrix} \text{Cov}(x_1, x_1) & \dots & \text{Cov}(x_1, x_d) \\ \vdots & \dots & \vdots \\ \text{Cov}(x_d, x_1) & \dots & \text{Cov}(x_d, x_d) \end{pmatrix} = \text{Cov}(\mathbf{x}, \mathbf{x})$$

Ну и понятно как эти вещи расширять на еще большие пространства.

**Многомерные распределения** Плотность многомерного равномерного распределения.

Пусть есть некое борелевское (ограниченное непрерывное) множество векторов  $S$ .  $\lambda(S)$  - объем множества (конечная мера Лебега). Тогда плотность определяется:

$$\rho(\mathbf{x}) = \begin{cases} \frac{1}{\lambda(S)} & \mathbf{x} \in S \\ 0 & \text{otherwise} \end{cases}$$

Плотность многомерного нормального распределения: Пусть у нас пространство размерности  $d$ . Определим плотность нормального распределения с матожиданием  $\mu$  и матрица ковариаций  $\Sigma$

$$\rho(\mathbf{x}) = \frac{1}{\sqrt{\det \Sigma} (\sqrt{2\pi})^n} \exp \left( \frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right)$$

Осталось осознать, что многомерные распределения, это частный случай совместных распределений, которые мы уже изучали в прошлом семестре:)

### Производные по матрице

Напомним что такое градиент и гессиан функции  $F(x_1, x_2, \dots, x_d)$

$$\nabla_{\mathbf{x}} F = \left( \frac{\partial F}{\partial x_1}, \dots, \frac{\partial F}{\partial x_d} \right)$$

$$\nabla^2 F = \begin{pmatrix} \frac{\partial^2 F}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 F}{\partial x_1 \partial x_d} \\ \vdots & \cdots & \vdots \\ \frac{\partial^2 F}{\partial x_d \partial x_1} & \cdots & \frac{\partial^2 F}{\partial x_d \partial x_d} \end{pmatrix}$$

Ну наверно никто не удивится тому, что

$$\nabla_{\mathbf{x}} F = \frac{\partial F}{\partial \mathbf{x}}$$

## 2.11 Ликбез по линалу. Многомерные распределения. Регрессия. Катарсис.

### Практика

1. Мы хотим восстановить некоторую функцию  $f(x)$  по данным аргументам  $x_i$  и значениям функции  $y_i$ . Используем метод линейной регрессии:

$$\mathbf{y} = \beta_1 \mathbf{x} + \beta_0 + \boldsymbol{\varepsilon}$$

$\boldsymbol{\varepsilon}$  - некий шум, который распределен нормально. Задача регрессии:

$$\sum_{i=1}^n \varepsilon_i^2 \rightarrow \min_{\beta_0, \beta_1}$$

Решите задачу регрессии: найдите параметры  $\beta_1$  и  $\beta_0$  и покажите их состоятельность.

2. Теперь у нас многомерная функция  $f(x_1, x_2, \dots, x_d)$ . Матрица аргументов -  $\mathbf{X}$  и ее значения  $\mathbf{y}$ . Решим задачу линейной регрессии для многомерной функции:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\sum_{i=1}^n \varepsilon_i^2 \rightarrow \min_{\boldsymbol{\beta}}$$

3. (Ridge Regression) Теперь поборемся с хреновой обусловленностью матрицы  $\mathbf{X}^T \mathbf{X}$ .

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda \boldsymbol{\beta}^T \boldsymbol{\beta}$$

4. Докажем, что задача регрессии эквивалентна задаче нахождения параметров методом максимального правдоподобия.

## 2.11 Ликбез по линалу. Многомерные распределения. Регрессия. Катарсис.

### Домашка

1. (4) Понятное дело, считать обратные матрицы - это полная жесьть. Поэтому вам надо записать формулы для нахождения  $\beta$  с помощью градиентного спуска для обычной и ridge регрессии. (Формулу градиентного спуска ищите в википедии яустал техать)
2. Доказать градиент и гессиан функций:
  - (a) (2) (Квадратичная функция)  $f(\mathbf{x}) = \frac{1}{2}(\mathbf{A}\mathbf{x})^T \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$
  - (b) (3) Куб нормы  $\frac{1}{3}||\mathbf{x}||_2^3$
3. Докажите, что (1) суммарная мера по всему пространству многомерного нормального распределения равна 1, (1) - матожидание, (2)  $\Sigma$  - матрица ковариаций. Да тут будет интегрирование по вектору (а кажется просто интегрирования по нескольким переменным). Достаточно двумерного распределения, если докажете для общего баллы умножатся на 2.
4. (1) А что будет, если добавить шум не только к  $\mathbf{y}$ , но и к  $\mathbf{x}$ ? Пусть нам известны  $\mathbf{y}$  и  $\mathbf{Z} = \mathbf{x} + \delta$ . Выпишите решение обычной задачи регрессии в этом случае. (3) Будет ли оценка состоятельной? (Спойлер нет, докажите)